

BLM308 Veri Madenciliği — Final Proje Raporu

Makine Öğrenmesi Algoritmaları ile AI Üretimi ve Gerçek Görsellerin Sınıflandırılması

Betül Yıldız — 231041019

Bahar 2026

Table of Contents

Takım Bilgileri ve Rol Dağılımı	2
Özet (Abstract)	2
1. Giriş	3
1.1. Problem Tanımı	3
1.2. Motivasyon ve İş Değeri	4
1.3. Literatür ve İlgili Çalışmalar	4
1.4. Raporun Yapısı	5
2. Yöntem (CRISP-DM)	5
2.1. Genel Akış	5
2.2. Kullanılan Araçlar	6
3. Veri	7
3.1. Veri Kaynağı	7
3.2. Veri Tanımı	8
3.3. Keşifsel Veri Analizi (EDA)	9
3.4. Ön İşleme	10
4. Model	11
4.1. Seçilen Algoritmalar	11
4.2. Deney Kurulumu	12
4.3. Hiperparametre Ayarı	13
5. Sonuçlar ve Tartışma	14
5.1. Performans Karşılaştırması	14
5.2. Confusion Matrix	16
5.3. İstatistiksel Test (3+ kişilik takımlar)	16
5.4. Bias-Variance Yorumu	17
5.5. Model Yorumlanabilirliği (XAI yapıldıysa)	17

5.6. Python Karşılaştırması (yapıldıysa)	18
6. Sonuç	18
6.1. Özet.....	18
6.2. Kısıtlar.....	19
6.3. Gelecek Çalışmalar	19
Kaynaklar	19
Ek A: Kod ve Veri Dizini.....	20
Ek B: Yapay Zeka Kullanımı Beyanı	21

Takım Bilgileri ve Rol Dağılımı

Ad Soyad	Numara	Rol	Yazdığı/Yaptığı Bölümler
Betül Yıldız	231041019	Veri Ön İşleme, Modelleme, Değerlendirme, Analiz ve Raporlama	Bölüm 1 (Giriş), Bölüm 2 (Yöntem), Bölüm 3 (Veri ve Ön İşleme), Bölüm 4 (Modelleme), Bölüm 5 (Sonuçlar ve Tartışma), Bölüm 6 (Sonuç), Python kodları (preprocess.py, train.py, evaluate.py), performans analizleri, grafikler, confusion matrix çıktıları ve rapor yazımı

Proje türü: Uçtan uca Python tabanlı görüntü sınıflandırma ve veri madenciliği projesi (Kaggle veri seti kullanılarak geliştirilmiştir)

Takım Büyüklüğüne Göre Ek Kapsam:

- Random Forest ve Extra Trees ensemble yöntemleri kullanılmıştır.
- Farklı makine öğrenmesi algoritmalarının performans karşılaştırması gerçekleştirilmiştir.
- Accuracy, Precision, Recall ve F1-score metrikleri kullanılarak detaylı değerlendirme yapılmıştır.
- Confusion Matrix ve performans grafikleri ile model analizleri gerçekleştirilmiştir.
- Python tabanlı tam veri madenciliği pipeline süreci uygulanmıştır.
- CRISP-DM yaklaşımının tüm temel aşamaları projede uygulanmıştır.

Özet (Abstract)

Bu çalışmada yapay zekâ tarafından üretilen görseller ile gerçek görsellerin makine öğrenmesi algoritmaları kullanılarak sınıflandırılması problemi ele alınmıştır. Son yıllarda üretken yapay zekâ teknolojilerinin hızlı gelişimi ile birlikte dijital ortamlarda oluşturulan

sahte görsel içeriklerin sayısı önemli ölçüde artmıştır. Bu durum bilgi güvenilirliği, dijital doğrulama, medya güvenliği ve içerik doğrulama süreçleri açısından önemli problemlere yol açmaktadır.

Bu çalışmada veri seti olarak Kaggle platformunda yayınlanan “AI vs Human Generated Images” veri seti kullanılmıştır. Veri setinin orijinal yapısında yaklaşık 79.950 eğitim görseli ve 5.540 test görseli bulunmaktadır. Çalışmada işlem maliyetlerini azaltmak ve eğitim süreçlerini daha kontrollü şekilde gerçekleştirmek amacıyla rastgele seçilen 3000 görsel kullanılmıştır.

Veri ön işleme aşamasında görseller 64x64 boyutuna dönüştürülmüş, RGB formatına çevrilmiş, normalize edilmiş ve makine öğrenmesi algoritmalarında kullanılabilmesi için sayısal özellik vektörlerine dönüştürülmüştür. Sınıflandırma işlemleri için Logistic Regression, Random Forest ve Extra Trees algoritmaları kullanılmıştır. Modeller Python programlama dili ve scikit-learn kütüphanesi kullanılarak geliştirilmiştir.

Model performansları Accuracy, Precision, Recall ve F1-score metrikleri kullanarak değerlendirilmiştir. Ayrıca Confusion Matrix ve performans grafikleri ile modeller detaylı olarak analiz edilmiştir. Elde edilen sonuçlara göre en başarılı model Random Forest algoritması olmuştur. Random Forest modeli yaklaşık %89 doğruluk oranı elde ederek diğer modellerden daha başarılı sonuç vermiştir.

Çalışma sonucunda ensemble tabanlı makine öğrenmesi yöntemlerinin yapay zekâ üretimi görsellerin tespit edilmesinde etkili ve başarılı sonuçlar verdiği görülmüştür.

Anahtar Kelimeler: Veri madenciliği, makine öğrenmesi, görüntü sınıflandırma, yapay zekâ, ensemble learning, Random Forest, Extra Trees, Python

1. Giriş

1.1. Problem Tanımı

Son yıllarda yapay zekâ teknolojilerinin hızlı gelişmesiyle birlikte gerçekçi görseller üretebilen sistemlerin kullanımı önemli ölçüde artmıştır. Özellikle üretken yapay zekâ modelleri sayesinde insanlar tarafından oluşturulmamış görseller oldukça gerçekçi hale gelmiştir. Bu durum dijital ortamlarda sahte içerik üretimi, dezenformasyon, manipülasyon ve bilgi güvenilirliği gibi önemli problemlerin ortaya çıkmasına neden olmuştur. Yapay zekâ tarafından oluşturulan görsellerin gerçek görsellerden ayırt edilmesi günümüzde önemli bir araştırma ve veri madenciliği problemi haline gelmiştir.

Özellikle sosyal medya platformları, haber siteleri ve dijital medya ortamlarında yapay zekâ üretimi görsellerin yaygınlaşması, yanlış bilgi yayılımı riskini artırmaktadır. İnsan gözüyle ayırt edilmesi zor olan bu içeriklerin otomatik yöntemlerle tespit edilmesi büyük önem

taşımaktadır. Bu nedenle görüntü sınıflandırma ve makine öğrenmesi yöntemleri kullanılarak gerçek ve yapay zekâ üretimi görsellerin ayrıştırılması önemli bir çalışma alanı olarak öne çıkmaktadır.

Bu çalışmada yapay zekâ üretimi görseller ile gerçek görsellerin makine öğrenmesi algoritmaları kullanılarak sınıflandırılması problemi ele alınmıştır. Çalışmanın temel amacı, görseller üzerinden özellik çıkarımı yaparak farklı makine öğrenmesi algoritmalarının performanslarını karşılaştırmak ve en başarılı modeli belirlemektir.

1.2. Motivasyon ve İş Değeri

Yapay zekâ destekli içerik üretim araçlarının gelişmesiyle birlikte dijital ortamlarda sahte görsellerin üretilmesi oldukça kolay hale gelmiştir. Bu durum özellikle sosyal medya, haber platformları, reklamcılık ve dijital medya alanlarında bilgi güvenilirliği açısından önemli riskler oluşturmaktadır. Yapay zekâ üretimi görsellerin gerçek içeriklerden ayırt edilememesi, yanlış bilgilendirme ve dijital manipölasyon problemlerini artırmaktadır.

Bu problemin çözümü medya kuruluşları, sosyal medya platformları, içerik doğrulama sistemleri ve güvenlik uygulamaları açısından büyük önem taşımaktadır. Geliştirilen sistemler sahte içerik analizi, deepfake tespiti, dijital doğrulama ve güvenilir içerik filtreleme gibi alanlarda kullanılabilir. Ayrıca bu tür sistemler dijital güvenlik uygulamalarında destekleyici bir araç olarak kullanılabilir.

Çalışmanın bir diğer motivasyonu ise makine öğrenmesi ve veri madenciliği yöntemlerinin gerçek dünya problemlerine uygulanabilirliğini göstermektir. Görüntü sınıflandırma problemleri üzerinde farklı algoritmaların performanslarının karşılaştırılması, veri madenciliği süreçlerinin uygulamalı olarak incelenmesine katkı sağlamaktadır. Bu çalışma aynı zamanda ensemble tabanlı yöntemlerin görüntü sınıflandırma problemlerindeki başarısını değerlendirmeyi amaçlamaktadır.

1.3. Literatür ve İlgili Çalışmalar

Son yıllarda yapay zekâ tabanlı görüntü üretim teknolojilerinin gelişmesiyle birlikte gerçekçi sahte görsellerin sayısında önemli artış yaşanmıştır. Özellikle üretken yapay zekâ modelleri ve derin öğrenme tabanlı görüntü üretim sistemleri sayesinde insanlar tarafından oluşturulmamış görseller oldukça gerçekçi hale gelmiştir. Bu durum dijital güvenlik, medya doğrulama ve bilgi güvenilirliği alanlarında yeni problemlerin ortaya çıkmasına neden olmuştur. Yapay zekâ üretimi içeriklerin otomatik olarak tespit edilmesi veri madenciliği ve makine öğrenmesi alanında önemli araştırma konularından biri haline gelmiştir [1][2].

Literatürde görüntü sınıflandırma problemleri için farklı makine öğrenmesi ve derin öğrenme yöntemleri kullanılmıştır. Özellikle Random Forest, Support Vector Machine (SVM), Logistic Regression ve Convolutional Neural Network (CNN) tabanlı yöntemlerin görüntü sınıflandırma problemlerinde başarılı sonuçlar verdiği belirtilmektedir [3][10]. Witten ve arkadaşlarına göre ensemble tabanlı yöntemler veri madenciliği süreçlerinde daha güçlü genelleme performansı sağlayabilmektedir [1]. Han ve arkadaşlarına göre veri ön işleme, modelleme ve değerlendirme aşamaları başarılı veri madenciliği süreçleri

açısından kritik öneme sahiptir [2]. Bishop ise makine öğrenmesi ve örüntü tanıma çalışmalarında sınıflandırma algoritmalarının veri özelliklerine göre farklı performans gösterebildiğini vurgulamıştır [10].

Son yıllarda yapılan çalışmalarda özellikle ensemble öğrenme yöntemlerinin görüntü sınıflandırma problemlerinde yüksek performans sağladığı görülmektedir. Random Forest ve Extra Trees gibi algoritmalar çoklu karar ağacı yapıları sayesinde daha güçlü genelleme performansı sağlayabilmektedir [3]. Ayrıca görüntü sınıflandırma çalışmalarında veri ön işleme, normalizasyon ve özellik dönüşümü işlemlerinin model başarısı üzerinde önemli etkileri olduğu belirtilmektedir. Goodfellow ve arkadaşları derin öğrenme tabanlı yöntemlerin görüntü işleme problemlerinde yüksek başarı sağladığını belirtmiş, ancak klasik makine öğrenmesi yöntemlerinin daha düşük işlem maliyetleri sayesinde belirli problemlerde etkili şekilde kullanılabileceğini ifade etmiştir [11].

Bu çalışmada literatürdeki benzer yaklaşımlar incelenmiş ve yapay zekâ üretimi görsellerin tespit edilmesi amacıyla farklı makine öğrenmesi algoritmalarının performansları karşılaştırılmıştır. Ayrıca Python tabanlı veri madenciliği pipeline sürecinin uçtan uca uygulanması ile literatürdeki benzer çalışmalara uygulamalı bir çalışma gerçekleştirilmiştir.

1.4. Raporun Yapısı


Bu rapor toplam altı ana bölümden oluşmaktadır. Birinci bölümde problem tanımı, motivasyon ve çalışma konusu ile ilgili temel bilgiler açıklanmıştır. İkinci bölümde CRISP-DM yaklaşımı kapsamında kullanılan yöntemler, proje akışı ve kullanılan araçlar açıklanmıştır. Üçüncü bölümde kullanılan veri seti, veri analizi ve veri ön işleme süreçleri detaylı olarak sunulmuştur. Dördüncü bölümde kullanılan makine öğrenmesi algoritmaları, modelleme süreci ve deney kurulumu açıklanmıştır. Beşinci bölümde performans sonuçları, confusion matrix analizleri ve model karşılaştırmaları değerlendirilmiştir. Son bölümde ise çalışma genel olarak değerlendirilmiş, elde edilen sonuçlar yorumlanmış ve gelecekte yapılabilecek geliştirmelerden bahsedilmiştir.

2. Yöntem (CRISP-DM)

2.1. Genel Akış

Bu çalışmada veri madenciliği süreci CRISP-DM yaklaşımına uygun şekilde gerçekleştirilmiştir. Süreç veri anlama, veri ön işleme, modelleme, değerlendirme ve sonuç analizi aşamalarından oluşmaktadır. İlk aşamada veri seti incelenmiş ve sınıf dağılımları analiz edilmiştir. Daha sonra görseller yeniden boyutlandırılmış, normalize edilmiş ve makine öğrenmesi modelleri için uygun hale getirilmiştir. Modelleme aşamasında farklı sınıflandırma algoritmaları kullanılarak performans karşılaştırmaları yapılmıştır. Son aşamada elde edilen sonuçlar değerlendirilmiş ve en başarılı model belirlenmiştir.

VERİ MADENCİLİĞİ VE MAKİNE ÖĞRENMESİ SÜRECİ (CRISP-DM)



Şekil 1. Projede uygulanan CRISP-DM tabanlı veri madenciliği ve makine öğrenmesi süreç akışı.

2.2. Kullanılan Araçlar

Bu çalışmada veri analizi, veri ön işleme, modelleme ve görselleştirme işlemleri için Python programlama dili kullanılmıştır. Proje geliştirme sürecinde farklı veri madenciliği ve makine öğrenmesi kütüphanelerinden yararlanılmıştır. Kullanılan araçlar ve teknolojiler aşağıda verilmiştir.

Python 3.12:

Projenin tüm veri işleme, modelleme ve değerlendirme işlemleri Python programlama dili kullanılarak gerçekleştirilmiştir.

Pandas:

Veri setinin okunması, analiz edilmesi ve veri işleme süreçlerinde kullanılmıştır.

Numpy:

Sayısal işlemler ve çok boyutlu veri yapılarının yönetilmesi amacıyla kullanılmıştır.

scikit-learn:

Logistic Regression, Random Forest ve Extra Trees modellerinin oluşturulması, eğitilmesi, test edilmesi ve performans değerlendirmelerinin gerçekleştirilmesi amacıyla kullanılmıştır.

Matplotlib:

Model performanslarının görselleştirilmesi, accuracy ve F1-score karşılaştırma grafiklerinin oluşturulması ile confusion matrix görsellerinin hazırlanması amacıyla kullanılmıştır.

Pillow (PIL):

Görsellerin okunması, yeniden boyutlandırılması ve RGB formatına dönüştürülmesi işlemlerinde kullanılmıştır.

Visual Studio Code:

Kod geliştirme, hata ayıklama ve proje yönetimi süreçlerinde geliştirme ortamı olarak kullanılmıştır.

Kaggle:

Projede kullanılan “AI vs Human Generated Images” veri setinin elde edildiği veri bilimi ve makine öğrenmesi platformudur.

Kullanılan araçlar sayesinde veri ön işleme, modelleme, performans değerlendirme ve görselleştirme süreçleri uçtan uca gerçekleştirilmiştir.

3. Veri

3.1. Veri Kaynağı

Bu çalışmada kullanılan veri seti, Kaggle platformunda yayınlanan “AI vs Human Generated Images” veri setinden elde edilmiştir. Veri seti, yapay zekâ tarafından üretilen görseller ile gerçek insanlar tarafından oluşturulmuş görselleri içermektedir. Çalışmada veri setinin eğitim (train) bölümü kullanılmıştır.

Veri setinin orijinal yapısında train_data klasöründe yaklaşık 79.950 eğitim görseli ve test_data_v2 klasöründe yaklaşık 5.540 test görseli bulunmaktadır. Veri seti içerisinde farklı kategorilerde gerçek ve yapay zekâ üretimi görseller yer almaktadır. Veri seti makine öğrenmesi, veri madenciliği ve görüntü sınıflandırma çalışmaları için uygun yapıda hazırlanmıştır.

Çalışmada veri setinin boyutunun oldukça büyük olması ve işlem maliyetlerinin kontrol altında tutulması amacıyla eğitim verilerinden rastgele seçilen 3000 görsel kullanılmıştır.

Böylece model eğitim ve değerlendirme süreçleri daha hızlı, kontrollü ve verimli şekilde gerçekleştirilmiştir.

Veri setindeki sınıf yapısında “0” etiketi gerçek (Human/Real) görselleri, “1” etiketi ise yapay zekâ tarafından oluşturulan (AI Generated) görselleri temsil etmektedir.

3.2. Veri Tanımı

Özellik	Açıklama
Veri seti adı	AI vs Human Generated Images
Veri kaynağı	Kaggle
Veri türü	Görüntü verisi
Örnek sayısı	3000 görsel (orijinal train_data: yaklaşık 79.950 görsel)
Görsel boyutu	64x64 piksel
Öznitelik sayısı	12.288 özellik (64×64×3 RGB)
Hedef değişken	Label
Sınıf sayısı	2 sınıf
Sınıf etiketleri	0 = Human/Real, 1 = AI Generated
Sınıf dengesi	Sınıflar arasında dengeli veri dağılımı bulunmaktadır
Veri formatı	JPG / PNG görüntü dosyaları
Kullanım amacı	Yapay zekâ üretimi görsellerin tespit edilmesi

Veri seti üzerinde gerçekleştirilen ön analizlerde eksik veri bulunmadığı gözlemlenmiştir. Görseller modelleme aşaması öncesinde normalize edilmiş, yeniden boyutlandırılmış ve makine öğrenmesi algoritmaları için uygun sayısal özellik vektörlerine dönüştürülmüştür.

3.3. Keşifsel Veri Analizi (EDA)



Şekil 2. Veri setindeki sınıf dağılımı.



Şekil 3. Veri setinden örnek gerçek (Human/Real) görsel.



Şekil 4. Veri setinden örnek yapay zekâ üretimi (AI Generated) görsel.

Veri seti üzerinde gerçekleştirilen keşifsel veri analizi çalışmaları sonucunda veri dağılımı, sınıf dengesi ve örnek görseller incelenmiştir. Şekil 2’de veri setindeki sınıf dağılımı gösterilmektedir. Veri setinin yaklaşık dengeli bir yapıya sahip olduğu görülmektedir. Bu durum model eğitim sürecinde sınıf dengesizliği problemini azaltarak daha güvenilir ve dengeli sonuçlar elde edilmesine katkı sağlamıştır.

Şekil 3 ve Şekil 4’te veri setinden seçilen örnek görseller gösterilmektedir. Gerçek görseller ile yapay zekâ üretimi görseller arasında doku, ışıklandırma, yüz detayları ve görüntü bütünlüğü açısından belirli farklılıklar gözlemlenmiştir. Özellikle yapay zekâ üretimi görsellerde bazı bölgelerde aşırı pürüzsüz yüzeyler, yapay detaylar ve gerçek dışı görüntü geçişleri dikkat çekmektedir. Bu farklılıkların makine öğrenmesi algoritmaları tarafından öğrenilerek sınıflandırma işlemlerinde kullanılabileceği değerlendirilmiştir.

Ayrıca veri seti üzerinde gerçekleştirilen ön analizlerde eksik veri bulunmadığı gözlemlenmiştir. Veri setinin dengeli yapıda olması nedeniyle ek bir sınıf dengeleme yöntemi uygulanmasına ihtiyaç duyulmamıştır. Veri seti modelleme öncesinde ön işleme aşamalarından geçirilerek makine öğrenmesi algoritmaları için uygun hale getirilmiştir.

3.4. Ön İşleme

Bu çalışmada veri seti modelleme aşamasından önce çeşitli ön işleme adımlarından geçirilmiştir. Amaç, görselleri makine öğrenmesi algoritmaları için uygun hale getirmek ve model performansını artırmaktır. Gerçekleştirilen ön işleme adımları aşağıda açıklanmıştır.

1. Eksik değer işleme:

Veri seti üzerinde gerçekleştirilen analizlerde eksik veri bulunmadığı gözlemlenmiştir. Bu nedenle eksik veri tamamlama veya silme işlemi uygulanmamıştır.

2. Outlier tespiti:

Çalışmada görüntü verileri kullanıldığı için klasik sayısal veri setlerinde kullanılan outlier analiz yöntemleri doğrudan uygulanmamıştır. Veri setindeki bozuk veya

okunamayan görseller kontrol edilmiş ve hatalı veriler eğitim sürecine dahil edilmemiştir.

3. **Normalizasyon / standardizasyon:**

Görsellerdeki piksel değerleri 0–255 aralığından 0–1 aralığına dönüştürülerek normalize edilmiştir. Böylece model eğitim sürecinde daha stabil ve verimli sonuçlar elde edilmesi amaçlanmıştır.

4. **Kodlama (Label Encoding):**

Veri setindeki sınıf etiketleri sayısal biçimde kullanılmıştır. “0” etiketi gerçek görselleri (Human/Real), “1” etiketi ise yapay zekâ üretimi görselleri (AI Generated) temsil etmektedir.

5. **Öznitelik seçimi ve dönüştürme:**

Tüm görseller 64x64 boyutuna yeniden ölçeklendirilmiş ve RGB formatına dönüştürülmüştür. Daha sonra görseller makine öğrenmesi algoritmalarında kullanılabilmesi için düzleştirme (flatten) işlemi uygulanarak sayısal özellik vektörlerine dönüştürülmüştür. Böylece her görsel toplam 12.288 özellikten oluşan bir veri yapısına dönüştürülmüştür.

6. **Dengesizlik tedavisi (SMOTE / class-weight):**

Veri setinin sınıf dağılımı yaklaşık dengeli olduğu için ek bir dengesizlik giderme yöntemi uygulanmamıştır. Bu nedenle SMOTE veya class-weight gibi yöntemlere ihtiyaç duyulmamıştır.

7. **Eğitim ve test ayrımı:**

Veri seti modelleme aşamasında %70 eğitim ve %30 test verisi olacak şekilde ayrılmıştır. Veri bölme işlemi sırasında sınıf dağılımının korunabilmesi için stratify yöntemi kullanılmıştır.

4. Model

4.1. Seçilen Algoritmalar

Bu çalışmada yapay zekâ üretimi görseller ile gerçek görsellerin sınıflandırılması amacıyla farklı makine öğrenmesi algoritmaları kullanılmıştır. Çalışmada hem temel sınıflandırma algoritmaları hem de ensemble tabanlı yöntemler tercih edilmiştir. Farklı algoritmaların kullanılması sayesinde model performansları karşılaştırılmış ve en başarılı yöntemin belirlenmesi amaçlanmıştır.

Kullanılan algoritmalar aşağıda açıklanmıştır:

MODEL	TÜR	KULLANIM AMACI / NOTLAR
LOGİSTİC REGRESSION	Doğrusal sınıflandırma	Temel karşılaştırma modeli olarak kullanılmıştır.
RANDOM FOREST	Ensemble öğrenme	Birden fazla karar ağacı kullanılarak güçlü sınıflandırma performansı elde edilmiştir.
EXTRA TREES	Ensemble öğrenme	Rastgeleleştirilmiş karar ağaçları ile hızlı ve güçlü sınıflandırma sağlanmıştır.

Logistic Regression

Logistic Regression algoritması doğrusal sınıflandırma problemlerinde yaygın olarak kullanılan temel makine öğrenmesi yöntemlerinden biridir. Çalışmada referans model olarak kullanılmış ve diğer gelişmiş modeller ile performans karşılaştırması yapılmıştır.

Random Forest

Random Forest algoritması çok sayıda karar ağacının birleşiminden oluşan ensemble tabanlı bir makine öğrenmesi yöntemidir. Rastgele örnekleme ve çoklu karar ağacı yapısı sayesinde aşırı öğrenme (overfitting) problemini azaltabilmektedir. Çalışmada en başarılı sonuçları veren model olmuştur.

Extra Trees

Extra Trees algoritması Random Forest yöntemine benzer şekilde ensemble öğrenme yaklaşımını kullanmaktadır. Ancak karar bölünmeleri daha rastgele oluşturulmaktadır. Bu sayede daha hızlı öğrenme ve güçlü genelleme performansı sağlanabilmektedir.

4.2. Deney Kurulumu

Bu çalışmada modellerin eğitim ve test işlemleri Python programlama dili ve scikit-learn kütüphanesi kullanılarak gerçekleştirilmiştir. Tüm deneyler aynı veri seti ve aynı ön işleme adımları kullanılarak uygulanmıştır.

Çalışmada kullanılan deney kurulumu aşağıda verilmiştir:

- **Veri bölme yöntemi:** %70 eğitim, %30 test
- **Sınıf dağılımı koruma yöntemi:** Stratified train-test split
- **Görsel boyutu:** 64x64 piksel
- **Normalizasyon:** Piksel değerleri 0–1 aralığına dönüştürülmüştür
- **Özellik dönüşümü:** Flatten işlemi uygulanmıştır
- **Random state:** 42

- **Toplam kullanılan veri sayısı:** 3000 görsel
- **Random Forest parametresi:** 100 karar ağacı (n_estimators=100)
- **Logistic Regression parametresi:** max_iter=1000
- **Extra Trees parametresi:** Varsayılan scikit-learn parametreleri kullanılmıştır

Model performanslarının değerlendirilmesinde Accuracy, Precision, Recall ve F1-score metrikleri kullanılmıştır. Ayrıca Confusion Matrix ve performans karşılaştırma grafikleri ile modeller detaylı olarak analiz edilmiştir.

Bu çalışmada deneylerin kontrollü ve tekrar üretilebilir şekilde gerçekleştirilebilmesi amacıyla rassallık işlemlerinde random_state değeri sabit tutulmuştur.

4.3. Hiperparametre Ayarı

Bu çalışmada kullanılan makine öğrenmesi algoritmalarında temel hiperparametre ayarlamaları gerçekleştirilmiştir. Modellerin performansını karşılaştırabilmek amacıyla kontrollü ve dengeli parametre seçimleri yapılmıştır. Bazı modellerde varsayılan parametreler kullanılırken, bazı modellerde eğitim sürecinin daha stabil çalışabilmesi için manuel parametre ayarları uygulanmıştır.

MODEL	PARAMETRE	DENENEN / KULLANILAN DEĞER	SEÇİLEN DEĞER
LOGİSTİC REGRESSION	max_iter	500, 1000	1000
LOGİSTİC REGRESSION	random_state	42	42
RANDOM FOREST	n_estimators	50, 100, 150	100
RANDOM FOREST	random_state	42	42
EXTRA TREES	random_state	42	42
EXTRA TREES	criterion	Varsayılan	gini
TRAIN/TEST SPLIT	test_size	%20, %30	%30
TRAIN/TEST SPLIT	stratify	True / False	True

Açıklama:

Çalışmada hiperparametre seçimleri model performansı, eğitim süresi ve deneylerin tekrar üretilebilir olması dikkate alınarak gerçekleştirilmiştir. Özellikle Random Forest modelinde kullanılan 100 karar ağacı değeri, performans ve işlem süresi açısından dengeli sonuçlar sağlamıştır. Logistic Regression modelinde ise iterasyon sayısı artırılarak modelin daha kararlı şekilde yakınsaması amaçlanmıştır.

Ayrıca tüm deneylerde rassallık kaynaklı farklılıkların azaltılması amacıyla random_state değeri sabit tutulmuştur. Böylece deney sonuçlarının tekrar üretilebilir olması sağlanmıştır.

5. Sonuçlar ve Tartışma

5.1. Performans Karşılaştırması

Bu çalışmada Logistic Regression, Random Forest ve Extra Trees algoritmalarının performansları karşılaştırılmıştır. Modeller Accuracy, Precision, Recall, F1-score ve eğitim süresi metrikleri kullanılarak değerlendirilmiştir. Elde edilen sonuçlar Tablo 2'de gösterilmektedir.


MODEL	ACCURACY	PRECİSİON	RECALL	F1-SCORE	SÜRE (S)
LOGİSTİC REGRESSION	0.6056	0.6426	0.4434	0.5248	7.84
RANDOM FOREST	0.8900	0.8595	0.9276	0.8923	14.38
EXTRA TREES	0.8789	0.8675	0.8891	0.8782	4.69

Tablo 2. Kullanılan makine öğrenmesi modellerinin performans sonuçları.


Açıklama:

Tablo 2 incelendiğinde en başarılı modelin Random Forest algoritması olduğu görülmektedir. Random Forest modeli yaklaşık %89 doğruluk oranı ve 0.8923 F1-score değeri elde ederek diğer modellerden daha yüksek performans göstermiştir. Extra Trees modeli de yüksek başarı sağlamasına rağmen Random Forest modelinin bir miktar gerisinde kalmıştır.

Logistic Regression modeli ise doğrusal yapısı nedeniyle görüntü verilerindeki karmaşık örüntüleri yeterince öğrenememiş ve diğer modellere göre daha düşük performans göstermiştir. Ensemble tabanlı yöntemlerin görüntü sınıflandırma problemlerinde daha başarılı sonuçlar verdiği gözlemlenmiştir.



Şekil 5. Modellerin accuracy değerlerinin karşılaştırılması.



Şekil 6. Modellerin F1-score değerlerinin karşılaştırılması.


Açıklama:

Şekil 5 ve Şekil 6 incelendiğinde Random Forest ve Extra Trees modellerinin Logistic Regression modeline göre belirgin şekilde daha yüksek performans gösterdiği görülmektedir. Özellikle ensemble öğrenme yöntemlerinin görüntü sınıflandırma problemlerinde daha başarılı sonuçlar ürettiği değerlendirilmiştir. Random Forest modeli hem accuracy hem de F1-score metriklerinde en yüksek değerlere ulaşarak çalışmadaki en

başarılı model olmuştur. Logistic Regression modelinin ise doğrusal yapısı nedeniyle görüntü verilerindeki karmaşık örüntüleri öğrenmekte yetersiz kaldığı gözlemlenmiştir.

5.2. Confusion Matrix

Bu çalışmada en başarılı performansı gösteren model olan Random Forest algoritması için confusion matrix analizi gerçekleştirilmiştir. Confusion matrix sonuçları modelin gerçek görseller ile yapay zekâ üretimi görselleri ne kadar başarılı şekilde sınıflandırabildiğini göstermektedir. Bu analiz sayesinde doğru sınıflandırılan ve yanlış tahmin edilen örnekler detaylı olarak incelenebilmektedir.



Şekil 7. Random Forest modeline ait confusion matrix sonucu.

Şekil 7 incelendiğinde Random Forest modelinin yüksek doğrulukla tahmin gerçekleştirdiği görülmektedir. Modelin hem gerçek görselleri hem de yapay zekâ üretimi görselleri büyük oranda doğru sınıflandırabildiği gözlemlenmiştir. Özellikle yapay zekâ üretimi görsellerin tespit edilmesinde yüksek başarı elde edilmiştir.

Confusion matrix sonuçlarına göre yanlış sınıflandırılan örnek sayısının sınırlı olduğu görülmektedir. Bu durum Random Forest algoritmasının görüntü sınıflandırma problemlerinde güçlü genelleme performansı sağladığını göstermektedir. Ensemble öğrenme yaklaşımının farklı karar ağaçlarının birleşiminden oluşması sayesinde modelin daha dengeli ve güvenilir sonuçlar üretebildiği değerlendirilmiştir.

5.3. İstatistiksel Test (3+ kişilik takımlar)

Bu çalışma bireysel proje kapsamında gerçekleştirildiği için paired t-test veya McNemar testi gibi ileri düzey istatistiksel testler uygulanmamıştır. Ancak modellerin performansları Accuracy, Precision, Recall ve F1-score metrikleri kullanılarak detaylı şekilde karşılaştırılmıştır.

Elde edilen sonuçlar incelendiğinde ensemble tabanlı yöntemlerin doğrusal sınıflandırma yöntemlerine göre daha başarılı sonuçlar verdiği görülmektedir. Özellikle Random Forest ve Extra Trees modellerinin görüntü verilerindeki karmaşık örüntüleri daha başarılı şekilde öğrenebildiği değerlendirilmiştir.

Model performansları arasındaki farkların belirgin olması, ensemble öğrenme yöntemlerinin görüntü sınıflandırma problemlerinde daha güçlü sonuçlar sağlayabildiğini göstermektedir. Bu durum Accuracy ve F1-score grafiklerinde de açık şekilde gözlemlenmektedir.

5.4. Bias-Variance Yorumu

Çalışmada kullanılan modeller bias-variance dengesi açısından incelendiğinde Logistic Regression modelinin daha yüksek bias değerine sahip olduğu değerlendirilmiştir. Modelin doğrusal yapısı nedeniyle görüntü verilerindeki karmaşık örüntüleri yeterince öğrenemediği görülmüştür. Bu durum modelin underfitting eğilimi göstermesine neden olmuştur.

Random Forest ve Extra Trees modelleri ise ensemble öğrenme yaklaşımını kullandıkları için daha düşük bias ve daha güçlü genelleme performansı göstermiştir. Özellikle Random Forest modeli çok sayıda karar ağacının birleşiminden oluştuğu için tek bir karar ağacına göre daha dengeli sonuçlar üretebilmiştir. Bu durum overfitting probleminin azaltılmasına katkı sağlamıştır.

Extra Trees modeli daha rastgele bölünmeler kullanması sayesinde hızlı öğrenme performansı göstermiştir. Ancak bazı durumlarda aşırı rastgelelik nedeniyle Random Forest modeline göre daha düşük doğruluk oranı elde edilmiştir. Genel olarak ensemble tabanlı yöntemlerin görüntü sınıflandırma problemlerinde daha başarılı sonuç verdiği gözlemlenmiştir.

5.5. Model Yorumlanabilirliği (XAI yapıldıysa)

Bu çalışmada SHAP veya LIME gibi ileri düzey açıklanabilir yapay zekâ yöntemleri uygulanmamıştır. Ancak confusion matrix sonuçları, performans karşılaştırma grafikleri ve değerlendirme metrikleri kullanılarak modellerin davranışları yorumlanmıştır.

Özellikle Random Forest ve Extra Trees modellerinin görüntü verilerindeki karmaşık örüntüleri Logistic Regression modeline göre daha başarılı şekilde öğrenebildiği gözlemlenmiştir. Ensemble öğrenme yöntemlerinin çoklu karar ağacı yapısı sayesinde daha güçlü genelleme performansı sağladığı değerlendirilmiştir.

Ayrıca performans metrikleri incelendiğinde Random Forest modelinin hem accuracy hem de F1-score açısından en başarılı sonuçları verdiği görülmektedir. Bu durum modelin gerçek ve yapay zekâ üretimi görseller arasındaki farklılıkları daha etkili şekilde öğrenebildiğini göstermektedir.

5.6. Python Karşılaştırması (yapıldıysa)

Bu proje tamamen Python programlama dili kullanılarak geliştirilmiştir. Veri ön işleme, modelleme, eğitim, test ve görselleştirme işlemleri pandas, numpy, scikit-learn, matplotlib ve Pillow (PIL) kütüphaneleri kullanılarak gerçekleştirilmiştir.

Python ortamında gerçekleştirilen deneyler sayesinde modellerin performansları detaylı şekilde analiz edilmiş ve farklı makine öğrenmesi algoritmalarının görüntü sınıflandırma problemleri üzerindeki etkileri karşılaştırılmıştır. Özellikle Random Forest ve Extra Trees modellerinin ensemble öğrenme yaklaşımı sayesinde daha başarılı sonuçlar verdiği gözlemlenmiştir.

Python tabanlı veri madenciliği süreci sayesinde veri ön işleme, modelleme, performans değerlendirme ve görselleştirme işlemleri uçtan uca gerçekleştirilmiştir. Tüm deneyler tekrar üretilebilir şekilde uygulanmış ve rassallık kontrolü için random_state parametresi sabit tutulmuştur.

Bu çalışma, Python ve scikit-learn kütüphanelerinin görüntü sınıflandırma ve veri madenciliği problemlerinde etkili şekilde kullanılabileceğini göstermektedir. Ensemble tabanlı yöntemlerin özellikle görüntü verilerinde daha başarılı sonuçlar üretebildiği değerlendirilmiştir.

6. Sonuç

6.1. Özet

Bu çalışmada yapay zekâ tarafından üretilen görseller ile gerçek görsellerin makine öğrenmesi algoritmaları kullanılarak sınıflandırılması problemi ele alınmıştır. Çalışmada Kaggle platformundan elde edilen “AI vs Human Generated Images” veri seti kullanılmış ve veri ön işleme aşamalarında görseller yeniden boyutlandırılmış, normalize edilmiş ve sayısal özellik vektörlerine dönüştürülmüştür.

Modelleme aşamasında Logistic Regression, Random Forest ve Extra Trees algoritmaları kullanılmıştır. Modeller Accuracy, Precision, Recall ve F1-score metrikleri ile değerlendirilmiş, ayrıca confusion matrix ve performans grafikleri kullanılarak detaylı analizler gerçekleştirilmiştir. Elde edilen sonuçlara göre en başarılı model Random Forest algoritması olmuştur. Ensemble tabanlı yöntemlerin görüntü sınıflandırma problemlerinde daha güçlü performans sağladığı gözlemlenmiştir.

Çalışma sonucunda makine öğrenmesi ve veri madenciliği yöntemlerinin yapay zekâ üretimi görsellerin tespit edilmesinde etkili şekilde kullanılabileceği görülmüştür. Ayrıca Python tabanlı veri madenciliği süreçlerinin uçtan uca uygulanabilirliği uygulamalı olarak gösterilmiştir.

6.2. Kısıtlar

Bu çalışmanın bazı sınırlılıkları bulunmaktadır. Öncelikle veri setinin orijinal boyutunun oldukça büyük olması nedeniyle işlem maliyetlerini azaltmak amacıyla veri setinden rastgele seçilen 3000 görsel kullanılmıştır. Daha büyük veri setleri kullanılması durumunda model performanslarında farklı sonuçlar elde edilebilir.

Çalışmada kullanılan görüntü boyutu 64x64 piksel ile sınırlandırılmıştır. Daha yüksek çözünürlüklü görseller kullanılması durumunda modellerin daha fazla detay öğrenebilmesi mümkün olabilir. Ancak bu durum işlem süresi ve donanım maliyetlerini artırmaktadır.

Ayrıca çalışmada klasik makine öğrenmesi algoritmaları kullanılmıştır. Derin öğrenme tabanlı CNN (Convolutional Neural Network) modelleri kullanılmamıştır. CNN tabanlı yöntemlerin görüntü sınıflandırma problemlerinde daha yüksek performans sağlayabileceği değerlendirilmektedir.

Bunun yanında SHAP ve LIME gibi ileri düzey açıklanabilir yapay zekâ yöntemleri uygulanmamıştır. Çalışma bireysel proje kapsamında ve sınırlı donanım kaynakları ile gerçekleştirildiği için bazı ileri düzey analizler projeye dahil edilmemiştir.

6.3. Gelecek Çalışmalar

Gelecek çalışmalarda daha büyük ve daha çeşitli veri setleri kullanılarak model performanslarının geliştirilmesi hedeflenebilir. Özellikle farklı kategorilerde yapay zekâ üretimi görsellerin kullanılması modellerin genelleme yeteneğini artırabilir.

Çalışmada kullanılan klasik makine öğrenmesi yöntemlerine ek olarak CNN, ResNet, EfficientNet ve Vision Transformer (ViT) gibi derin öğrenme tabanlı görüntü sınıflandırma modelleri uygulanabilir. Bu yöntemlerin özellikle yüksek çözünürlüklü görüntüler üzerinde daha başarılı sonuçlar verebileceği düşünülmektedir.

Ayrıca SHAP ve LIME gibi açıklanabilir yapay zekâ yöntemleri kullanılarak modellerin karar mekanizmaları daha detaylı şekilde analiz edilebilir. Böylece hangi görsel özelliklerin sınıflandırma sürecinde daha etkili olduğu incelenebilir.

Bunun yanında geliştirilen sistem gerçek zamanlı çalışan bir web uygulamasına dönüştürülebilir. Böylece kullanıcılar yükledikleri görsellerin yapay zekâ üretimi olup olmadığını otomatik olarak analiz edebilirler. Bu tür sistemler sosyal medya platformları, haber doğrulama sistemleri ve dijital güvenlik uygulamalarında kullanılabilir.

Kaynaklar

[1] Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2017). *Data Mining: Practical Machine Learning Tools and Techniques* (4th Edition). Morgan Kaufmann.

[2] Han, J., Kamber, M., & Pei, J. (2022). *Data Mining: Concepts and Techniques* (4th Edition). Morgan Kaufmann.

- [3] Pedregosa, F. ve diğerleri. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research.
[scikit-learn Documentation](#)
- [4] Kaggle – *AI vs Human Generated Images Dataset*.
[Kaggle Dataset](#)
- [5] Python Software Foundation. *Python Programming Language Documentation*.
[Python Official Documentation](#)
- [6] McKinney, W. *pandas: Powerful Python Data Analysis Toolkit*.
[Pandas Documentation](#)
- [7] Harris, C. R. ve diğerleri. *Array programming with NumPy*. Nature, 2020.
[NumPy Documentation](#)
- [8] Hunter, J. D. (2007). *Matplotlib: A 2D Graphics Environment*. Computing in Science & Engineering.
[Matplotlib Documentation](#)
- [9] Python Imaging Library (PIL) Documentation.
[Pillow Documentation](#)
- [10] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
[Springer – Pattern Recognition and Machine Learning](#)
- [11] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
[Deep Learning Book](#)
-

Ek A: Kod ve Veri Dizini

VeriMadenciligi_Final_Projesi/

|

|— rapor.docx

|— rapor.pdf

|— README.md

|— BONUSLAR.md

|— demo_video.mp4

|

|— kod/

```
|   ├── preprocess.py
|   ├── train.py
|   ├── evaluate.py
|   └── eda.py
|
|── ciktilar/
|   ├── class_distribution.png
|   ├── accuracy_comparison.png
|   ├── f1_comparison.png
|   ├── best_model_confusion_matrix.png
|   └── model_sonucлари.csv
|
|── veri/
|   └── README.md
```

Bu proje kapsamında veri ön işleme, keşifsel veri analizi (EDA), model eğitimi, performans değerlendirme ve görselleştirme işlemleri tamamen Python ortamında gerçekleştirilmiştir. Proje yapısı modüler şekilde hazırlanmış ve tüm deneyler tekrar üretilebilir biçimde düzenlenmiştir. Grafikler ve performans çıktıları otomatik olarak “ciktilar” klasörüne kaydedilmektedir.

Ek B: Yapay Zeka Kullanımı Beyanı

Bu proje geliştirme sürecinde yapay zekâ destek araçlarından sınırlı düzeyde yararlanılmıştır. ChatGPT yapay zekâ sistemi; akademik yazım düzeni, rapor formatı, teknik açıklamaların geliştirilmesi ve bazı kod düzenleme işlemlerinde yardımcı araç olarak kullanılmıştır.

Proje kapsamında kullanılan veri ön işleme, modelleme, performans değerlendirme ve görselleştirme kodları proje sahibi tarafından geliştirilmiş, çalıştırılmış ve doğrulanmıştır. Tüm deney sonuçları kullanıcı tarafından elde edilmiş ve rapora manuel olarak aktarılmıştır.

Yapay zekâ araçları yalnızca destekleyici yardımcı araç olarak kullanılmış olup proje içeriğinin akademik sorumluluğu tamamen proje sahibine aittir.

Ek C: GitHub Repo Baęlantısı

Proje kaynak kodları ve proje dosyaları ařaęıdaki GitHub reposunda paylaşılmıřtır:

<https://github.com/betulyilddiz/ai-vs-human-images>